
Guía del Proyecto Integrador

Asignatura: Machine Learning I

1. Instrucciones generales

1. El proyecto se desarrolla en grupo durante todo el semestre y se evalúa en tres entregas: **Primera entrega**, **Segunda entrega** y **Entrega final**, cada una asociada a una de las tres sesiones de retroalimentación del proyecto previstas en el microcurrículo. Cada entrega incluye un informe y una sustentación oral.
2. Cada grupo entrega un documento con las secciones indicadas para la entrega correspondiente, junto con el código ejecutable y reproducible que respalde los resultados.
3. El proyecto avanza de manera acumulativa: cada entrega parte de la anterior y la profundiza, hasta consolidar un flujo de modelamiento supervisado completo.
4. Se debe cuidar la ortografía y la gramática. Se restarán puntos por errores ortográficos o gramaticales.

2. Enfoque del proyecto integrador

El proyecto integrador tiene como propósito que el estudiante aplique, sobre un problema real, el flujo completo del modelamiento supervisado propio de *Machine Learning I*: **formulación del problema predictivo, preprocesamiento integrado en un flujo reproducible, entrenamiento de modelos, validación rigurosa sin fuga de datos, evaluación mediante métricas, interpretación y despliegue básico**. El enfoque del curso es predictivo y metodológico; el énfasis está en el criterio para construir, validar e interpretar modelos con las técnicas del curso.

El proyecto se organiza en torno a un **artículo científico**, seleccionado de una lista provista por el profesor, que emplea **exclusivamente** modelos vistos en *Machine Learning I*. El trabajo consiste en tres movimientos encadenados: (1) **entender y sustentar el artículo** —su problema, su modelo, sus supuestos y sus resultados—; (2) **conseguir los datos en clave local** —un conjunto de datos colombiano o latinoamericano real, una **simulación fundamentada** que reproduzca casos realistas de ese fenómeno, o una combinación de ambos—; y (3) **reproducir los objetivos del artículo** sobre esos datos, aplicando estrictamente las técnicas del curso, con el flujo completo de modelamiento. No se trata de replicar el código de los autores, sino de reconstruir su propósito con criterio propio.

El proyecto se resuelve **únicamente con los modelos del curso** (KNN, Naive Bayes, regresión lineal y logística, análisis discriminante y regularización). No se recurre a modelos no lineales avanzados, ensambles ni redes neuronales, propios de *Machine Learning II* y cursos posteriores: el reto no está en la sofisticación del algoritmo, sino en la solidez del flujo, la validación y la interpretación.

El papel central de la simulación fundamentada. La construcción de datos mediante simulación es, académicamente, uno de los componentes más valiosos del proyecto. Para simular bien un caso colombiano o latinoamericano no basta con generar números al azar: hay que comprender la **estructura generadora de los datos** —las distribuciones de las variables, las relaciones y dependencias entre ellas y las proporciones plausibles del fenómeno—. Ese ejercicio exige **pensamiento estadístico profundo** y obliga al estudiante a entender el problema por dentro, no solo a ejecutar un modelo. Por eso el proyecto se apoya en artículos que usan modelos clásicos del curso, en los que la estructura del fenómeno es transparente y puede reconstruirse de forma justificada; con modelos de caja negra esa transparencia se pierde y la simulación deja de tener anclaje. Cuando el equipo opte por simular, total o parcialmente, debe **justificar explícitamente** por qué su simulación representa un caso realista: qué distribuciones y relaciones asume y en qué evidencia o supuestos del contexto se basa.

El proyecto marca la frontera con los cursos vecinos de la línea. A diferencia de *Data Mining*, cuyo proyecto es descriptivo y culmina en un dataset analítico depurado, aquí el trabajo consiste en **modelar**: entrenar, validar, comparar e interpretar. El proyecto avanza de manera acumulativa a lo largo de las tres entregas y culmina en un **modelo predictivo validado e interpretado, con un despliegue básico funcional**, junto con su comunicación de resultados y sustentación.

3. Herramientas y autoría

- **Software.** El proyecto se desarrolla en **Python**, utilizando **scikit-learn** para el modelamiento y la validación, y librerías de apoyo como **pandas** y **matplotlib**. El despliegue básico se realiza con **Streamlit**. Todo el código debe ser ejecutable y reproducible.
- **Reproducibilidad.** El flujo completo —preprocesamiento, entrenamiento, validación y evaluación— debe integrarse en una estructura reproducible (por ejemplo, mediante **Pipeline**), de modo que las mismas transformaciones se apliquen de forma idéntica y trazable. Se debe fijar una semilla aleatoria para garantizar la repetibilidad.
- **Autoría.** Todos los productos deben ser originales y elaborados para este curso. El uso de código, librerías o repositorios externos se permite solo si se citan de manera explícita. El uso de herramientas de inteligencia artificial generativa se permite como apoyo, siempre que se declare y que el equipo comprenda y pueda sustentar cada decisión técnica.
- **Responsabilidad compartida.** Todos los integrantes comparten la responsabilidad académica y deben poder explicar y sustentar las decisiones metodológicas, técnicas y analíticas en cualquiera de sus fases. El profesor podrá solicitar aclaraciones individuales o evidencias de participación.

4. Directrices de formato, extensión y concisión

- **Formato del documento.** Cada entrega se presenta con portada (título del proyecto, integrantes y curso), estructura clara por secciones y numeración de figuras y tablas. El código se entrega como anexo o mediante enlace a un repositorio.
- **Extensión del texto.** El cuerpo del informe (excluyendo portada, bibliografía, gráficos y tablas) debe tener una extensión **mínima de 3 y máxima de 5 páginas**. Documentos con menos de 3 páginas se consideran superficiales y pueden ser penalizados; los que excedan las 5 páginas se truncan para su evaluación o se penalizan en la rúbrica de comunicación.
- **Concisión y rigor.** Se valora la precisión técnica sobre la extensión. El texto debe justificar cada decisión —preprocesamiento, elección de modelo, validación, métricas— de forma breve y fundamentada, evitando la descripción mecánica de procedimientos o la repetición de teoría vista en clase.
- **Evidencia visual.** Las figuras y tablas (curvas de validación, matrices de confusión, curvas ROC, comparaciones de métricas) deben aportar información y estar interpretadas en el texto; no se incluyen gráficos sin lectura ni salidas de código sin análisis.

5. Tareas iniciales

5.1. Organizar el equipo de trabajo

El proyecto se desarrolla en equipo, conformado dentro del plazo establecido al inicio del semestre. Una vez registrados, los equipos se consideran definitivos y solo se modifican en situaciones excepcionales avaladas por el profesor. Se espera participación activa y equitativa de todos los integrantes en todas las fases.

5.2. Seleccionar y comprender el artículo base

El proyecto se organiza en torno a un **artículo científico**, seleccionado de la lista provista por el profesor. Cada equipo elige un único artículo y trabaja sobre él durante todo el semestre. El artículo base debe:

- Emplear **exclusivamente** modelos vistos en el curso: KNN, Naive Bayes, regresión lineal, regresión logística, análisis discriminante (LDA/QDA) o regularización.
- Ser un artículo **aplicado**, en el que el modelo se usa como herramienta para responder una pregunta de un dominio real (salud, economía, educación, ciencias sociales u otro).
- Presentar de forma **transparente** la estructura del problema y de los datos —variables, relaciones y objetivos—, de modo que sus objetivos puedan reconstruirse y, si es el caso, simularse con fundamento.
- **No** depender de modelos avanzados, ensambles, métodos kernel o redes neuronales, propios de *Machine Learning II*.

El primer trabajo del equipo es **entender y sustentar el artículo**: el problema que aborda, el modelo que emplea, sus supuestos y sus resultados. Esta comprensión es la base de las fases siguientes; el objetivo no es replicar el código de los autores, sino reproducir sus **objetivos** con las técnicas del curso.

5.3. Conseguir los datos: dataset local o simulación fundamentada

Para reproducir los objetivos del artículo en un contexto propio, el equipo consigue los datos en **clave colombiana o latinoamericana**, por una de tres vías:

- **Dataset real**: un conjunto de datos local pertinente, de una fuente verificable (repositorio público, entidad o portal de datos abiertos).
- **Simulación fundamentada**: un conjunto generado por el equipo que reproduzca casos realistas del fenómeno, basándose en la estructura descrita en el artículo —distribuciones, relaciones entre variables y proporciones plausibles del contexto—.
- **Combinación**: un dataset real complementado o ampliado con datos simulados de forma justificada.

En cualquiera de las vías, el conjunto debe corresponder a un problema **supervisado** con variable objetivo claramente definida (clasificación o regresión), tener al menos **5000 registros** y permitir el flujo completo del curso con particiones sin fuga de información. Cuando se recurra a la simulación —total o parcial—, el equipo debe **justificarla explícitamente**: qué distribuciones y relaciones asume, en qué evidencia o supuestos del contexto se apoya y por qué representa un caso realista. La calidad de esta justificación es un criterio central de evaluación.

6. Primera entrega

La Primera entrega corresponde a la **Fase 1: comprensión del artículo y planteamiento**. El equipo sustenta el artículo base, define el problema que reproducirá y establece cómo conseguirá los datos. Se entrega el informe y se sustenta oralmente en la primera sesión de retroalimentación del proyecto.

6.1. Comprensión y sustentación del artículo

El equipo expone el artículo base: el problema que aborda, el modelo que emplea, sus supuestos principales, los resultados reportados por los autores y sus limitaciones. Se demuestra comprensión profunda del enfoque, en un nivel que permita defenderlo oralmente y reproducir sus objetivos con las técnicas del curso.

6.2. Planteamiento del problema

A partir del artículo, el equipo formula el **problema supervisado** que reproducirá: la pregunta a responder, el tipo de tarea (clasificación o regresión), la variable objetivo y su relevancia en el contexto colombiano o latinoamericano. Se explicita qué objetivos del artículo se reproducirán y con qué técnicas del curso.

6.3. Estrategia de datos

El equipo define cómo conseguirá los datos —dataset real, simulación fundamentada o combinación— y lo justifica. Si contempla simulación, describe la estructura que reproducirá (distribuciones, relaciones y proporciones) y su fundamento. Se caracteriza el conjunto previsto: variable objetivo, predictores, tamaño y calidad inicial.

6.4. Plan de modelamiento y línea base

El equipo propone los modelos candidatos del curso que comparará, la métrica principal de evaluación (justificada según el problema y el costo del error) y la estrategia de validación prevista. Construye además un **modelo de línea base** (clasificador de mayoría o predictor de la media) como referencia mínima.

6.5. Rúbrica de la Primera entrega

Criterio	Excelente (4.0–5.0)	Bueno (3.0–3.9)	Aceptable (2.0–2.9)	Deficiente (0.0–1.9)
Comprensión y sustentación del artículo	Dominio profundo del artículo (problema, modelo, supuestos, resultados); se defiende con solvencia.	Buena comprensión del artículo, con algún vacío.	Comprensión superficial; sustentación dependiente de un integrante.	No se comprende el artículo o no se sustenta.
Planteamiento del problema	Problema supervisado, tarea y variable objetivo definidos con precisión y relevancia clara.	Problema y variable objetivo definidos, con relevancia poco desarrollada.	Formulación genérica o ambigua.	No se define un problema supervisado válido.
Estrategia de datos y simulación	Vía de datos bien justificada; si hay simulación, su estructura y fundamento son sólidos.	Estrategia de datos definida; justificación de la simulación básica.	Estrategia poco clara o simulación sin fundamento.	Sin estrategia de datos o simulación arbitraria.
Plan de modelamiento y línea base	Modelos candidatos, métrica principal justificada y línea base bien definida.	Plan y línea base presentes, con justificación limitada de la métrica.	Plan incompleto; línea base ausente o métrica sin justificar.	No hay plan de modelamiento ni línea base.
Comunicación, informe y sustentación	Informe claro y conciso; sustentación sólida, con dominio de todo el equipo.	Informe claro; sustentación correcta con algunos vacíos.	Informe desorganizado; sustentación débil.	Informe incompleto; sustentación deficiente o ausente.

7. Segunda entrega

La Segunda entrega corresponde a la **Fase 2: datos, modelamiento y validación**. El equipo consolida el conjunto de datos, construye el flujo de modelamiento, entrena y compara modelos del curso y evalúa su desempeño con rigor. Se entrega el informe con el código reproducible y se sustenta oralmente en la segunda sesión de retroalimentación.

7.1. Consolidación de los datos

El equipo presenta el conjunto de datos definitivo (real, simulado o combinado). Si hubo simulación, muestra cómo se generó y verifica que reproduce la estructura prevista (distribuciones, relaciones y proporciones). Se reporta el estado de calidad y las transformaciones necesarias.

7.2. Flujo reproducible sin fuga de datos

Se integra el preprocesamiento y el modelado en un flujo reproducible (por ejemplo, **Pipeline**), garantizando que las transformaciones —imputación, codificación, escalamiento, balanceo, selección— se ajusten solo con los datos de entrenamiento de cada partición. Se explicita el orden de las etapas y por qué previene la fuga de información.

7.3. Entrenamiento y comparación de modelos

Se entrenan varios modelos del curso (KNN, Naive Bayes, regresión lineal o logística, LDA/QDA) comparándolos entre sí y frente a la línea base, con un ajuste inicial de hiperparámetros mediante validación cruzada cuando corresponda. La comparación se sustenta en evidencia.

7.4. Validación, métricas e interpretación preliminar

Se aplica una estrategia de validación adecuada y se evalúan los modelos con las métricas pertinentes, justificadas según el problema y el desbalance. Se reportan los resultados con su variabilidad y se ofrece una primera lectura del mejor modelo: variables relevantes, errores e implicaciones.

7.5. Rúbrica de la Segunda entrega

Criterio	Excelente (4.0–5.0)	Bueno (3.0–3.9)	Aceptable (2.0–2.9)	Deficiente (0.0–1.9)
Consolidación de los datos	Datos consolidados y verificados; la simulación (si la hay) reproduce fielmente la estructura prevista.	Datos consolidados; verificación básica de la simulación.	Datos con inconsistencias o simulación poco verificada.	Datos inadecuados o simulación injustificada.
Flujo sin fuga de datos	Flujo integrado y reproducible; se evita y justifica correctamente la ausencia de fuga.	Flujo reproducible; manejo de la fuga correcto pero poco explicado.	Flujo parcial; riesgo de fuga no advertido.	Fuga presente o flujo no reproducible.
Entrenamiento y comparación	Varios modelos comparados con criterio frente a la línea base; ajuste bien fundamentado.	Modelos entrenados y comparados; ajuste limitado.	Pocos modelos o comparación superficial.	Un solo modelo sin comparación.
Validación, métricas e interpretación	Validación adecuada, métricas justificadas e interpretación preliminar clara.	Validación correcta; métricas pertinentes con interpretación básica.	Validación débil o interpretación superficial.	Sin validación adecuada o métricas incorrectas.
Comunicación, informe y sustentación	Informe claro y reproducible; sustentación sólida, con dominio de todo el equipo.	Informe claro; sustentación correcta con algunos vacíos.	Informe desorganizado; sustentación débil.	Informe incompleto; sustentación deficiente o ausente.

8. Entrega final

La Entrega final corresponde a la **Fase 3: consolidación, despliegue y comunicación**. El equipo cierra el flujo completo, selecciona y justifica el modelo final, lo interpreta a la luz de los objetivos del artículo, lo despliega de forma básica y comunica los resultados. Se entrega el informe técnico final con el código reproducible y se sustenta oralmente en la tercera sesión de retroalimentación.

8.1. Modelo final y reproducción de los objetivos del artículo

El equipo selecciona el modelo final a partir de la comparación validada, justificando la decisión con base en las métricas, la estabilidad y el equilibrio entre desempeño e interpretabilidad. Se contrasta el resultado con los **objetivos del artículo**: en qué medida se lograron reproducir en el contexto local y qué diferencias aparecieron. Se documenta la configuración definitiva y la evaluación sobre el conjunto de prueba.

8.2. Interpretación de resultados

Se interpreta el modelo final en términos del problema: variables o factores más influyentes, tipos de error y sus implicaciones prácticas, y alcance de las conclusiones. La interpretación traduce los resultados técnicos a un lenguaje comprensible para el contexto de aplicación.

8.3. Despliegue básico

El equipo implementa un despliegue básico y funcional del modelo (por ejemplo, una aplicación simple en **Streamlit**) que reciba entradas, aplique el flujo de preprocesamiento y predicción, y devuelva un resultado. Se verifica la coherencia entre los datos de entrenamiento y los de uso, y se documenta cómo ejecutar la aplicación.

8.4. Calidad, limitaciones y proyección

Se discuten las limitaciones del trabajo (calidad o realismo de los datos, supuestos de la simulación, riesgo de sobreajuste, generalización) y se proponen mejoras o líneas de continuidad, incluyendo su proyección hacia técnicas más avanzadas que se abordan en *Machine Learning II*.

8.5. Sustentación oral

Cada equipo sustenta el proyecto en una presentación oral, exponiendo el artículo y sus objetivos, la estrategia de datos, el flujo de modelamiento, los resultados y su interpretación, y demostrando el despliegue. Todos los integrantes deben estar en capacidad de explicar y defender las decisiones técnicas del proyecto.

8.6. Rúbrica de la Entrega final

Criterio	Excelente (4.0–5.0)	Bueno (3.0–3.9)	Aceptable (2.0–2.9)	Deficiente (0.0–1.9)
Modelo final y reproducción de objetivos	Modelo final bien justificado; los objetivos del artículo se reproducen y contrastan con claridad.	Modelo final justificado; reproducción de objetivos presente pero parcial.	Selección poco justificada o reproducción confusa de los objetivos.	Modelo final sin justificar o sin relación con el artículo.
Interpretación de resultados	Interpretación clara, conectada con el problema y traducida al contexto.	Interpretación correcta pero con profundidad limitada.	Interpretación superficial o desconectada de los resultados.	Sin interpretación de resultados.
Despliegue básico	Despliegue funcional y reproducible, coherente con el flujo y bien documentado.	Despliegue funcional con documentación básica.	Despliegue incompleto o con inconsistencias.	Sin despliegue o no funcional.
Calidad, limitaciones y proyección	Discusión honesta de limitaciones (incluida la simulación) y mejoras bien fundamentadas.	Limitaciones y mejoras presentes pero generales.	Mención superficial de limitaciones.	Sin discusión de limitaciones ni proyección.
Comunicación, informe y sustentación	Informe técnico sólido y sustentación clara; dominio integral por todo el equipo.	Informe claro y sustentación correcta con algunos vacíos.	Informe o sustentación desorganizados o dependientes de un integrante.	Informe incompleto; sustentación deficiente o ausente.

9. Evaluación y ponderación

El proyecto integrador corresponde al **20% de la nota final del curso**, según el marco de evaluación del microcurrículo. Su calificación resulta de las tres entregas, cada una evaluada con su respectiva rúbrica sobre una escala de **0.0 a 5.0**. El peso de cada entrega dentro de la nota del proyecto es el siguiente:

- **Primera entrega** (Fase 1 – comprensión del artículo y planteamiento): 20 %
- **Segunda entrega** (Fase 2 – datos, modelamiento y validación): 40 %
- **Entrega final** (Fase 3 – consolidación, despliegue y comunicación): 40 %

Cada entrega incluye informe y sustentación oral, y se califica de manera independiente con los criterios de su rúbrica. La no entrega de una fase implica una calificación de cero (0.0) en dicha fase, sin eximir al equipo de presentar las fases restantes. Todos los integrantes deben estar en capacidad de sustentar las decisiones del proyecto; el profesor podrá realizar ajustes evaluativos individuales ante inconsistencias, desequilibrios en la carga de trabajo o problemas de autoría. ML1 - Microcurrículo